



**ESCUELA TÉCNICA SUPERIOR
DE
INGENIERIA INFORMÁTICA**

Trabajo Fin de Máster

Máster en Lógica Computación e Inteligencia Artificial

Sing2Text: Traducción basada en KeyPoints

Realizado por

Nicolás Rodríguez Ruiz

Tutorizado por

Miguel Ángel Martínez Del Amor

Departamento de

Ciencias de la Computación e Inteligencia Artificial

Sevilla, 29 de abril de 2026

Índice general

1	Introducción	7
1.1	Resumen	7
1.2	Motivación y Planteamiento	7
1.3	Objetivo	8
2	Estado del Arte	9
2.1	General (traducción en SL)	9
2.1.1	Modelos basados en Glosas	9
2.1.2	Modelos <i>End2End</i>	9
2.2	Uso de keypoints como entrada a modelos en SL	9
2.3	Datasets	9
3	Metodología	11
3.1	Extracción de Keypoints	11
3.1.1	Alphapose	11
3.2	Seq2Seq	13
3.3	Normalización de los Datos	13
3.4	Transformers	13
3.4.1	¿Qué es un Transformer?	13
4	Experimentación y análisis de resultados	15
4.1	Ablation study	15
4.2	Comparativa con state of the art	15
4.3	También comparar la eficiencia	15
5	Conclusión y trabajo futuro	17

Capítulo 1

Introducción

1.1. Resumen

1.2. Motivación y Planteamiento

Según los datos de la Organización Mundial de la Salud, más de 1,500 millones de personas en el mundo viven con algún grado de pérdida auditiva, de las cuales aproximadamente 430 millones requieren atención especializada. Para una parte significativa de esta población, la lengua de signos es su principal medio de comunicación natural. Sin embargo, el acceso a servicios esenciales como lo son la sanidad, la educación o la administración pública sigue dependiendo casi exclusivamente de intérpretes humanos, un recurso escaso, costoso y con disponibilidad geográfica muy desigual. Esta dependencia limita la autonomía de las personas sordas y perpetúa una brecha de inclusión social difícil de cerrar sin el apoyo de soluciones tecnológicas escalables.

En los últimos años ha habido enormes avances en las técnicas de *Procesamiento del Lenguaje Natural*, *Visión por Computador* y *Aprendizaje Profundo*, así como en la eficiencia y capacidad computacional de los equipos, sin embargo las lenguas de signos han recibido una atención comparativamente menor, y los avances no han alcanzado el nivel de madurez ni la cobertura lingüística que sí presentan los sistemas para lenguas orales. Los sistemas de traducción automática, los asistentes conversacionales y las interfaces de voz han transformado la forma en que las personas oyentes interactúan con la tecnología, pero siguen siendo inaccesibles para quienes se comunican mediante el canal viso-gestual.

Para abordar esta brecha, la investigación en traducción automática de lengua de signos se articula principalmente en torno a dos direcciones complementarias: por un lado, la traducción de texto o voz a lengua de signos, **Text2Sign**, orientada a facilitar la comprensión por parte de personas sordas; por otro, la traducción de lengua de signos a texto, **Sign2Text**, cuyo objetivo es permitir que las personas oyentes o los sistemas automáticos comprendan los mensajes signados. El presente trabajo se centra en esta

segunda dirección, **Sign2Text**, por su impacto directo en la autonomía comunicativa de las personas sordas y por los retos técnicos abiertos que aún presenta.

La tarea **Sign2Text**, también conocida como *Sign Language Recognition and Translation*, persigue la generación automática de texto a partir de una secuencia de signos capturada en vídeo. Un sistema de este tipo permitiría subtitular en tiempo real una conversación signada, dotar a los asistentes virtuales de la capacidad de entender a usuarios sordos, o facilitar el acceso a servicios públicos sin necesidad de un intérprete presente. En definitiva, actuaría como un puente de comunicación directo entre la comunidad sorda y los sistemas digitales diseñados, hasta ahora, pensando exclusivamente en usuarios oyentes.

Desde el punto de vista técnico, Sign2Text es un problema especialmente complejo. A diferencia del reconocimiento de voz, donde la señal de entrada es unidimensional y continua, la lengua de signos es inherentemente multimodal: la información se distribuye simultáneamente entre la configuración y el movimiento de las manos, la expresión facial, la postura corporal y el uso del espacio. Esta riqueza expresiva, que dota a las lenguas de signos de toda su potencia comunicativa, supone al mismo tiempo uno de los mayores desafíos para su modelado automático. A esto se le suma la gran variedad de lenguas de signos que existen, cada una con sus gestos y expresiones visuales únicas, además en la mayoría de los casos, la lengua de signos de una determinada región carece de relación gramatical con la lengua natural de dicha región. Esto dificulta significativamente la comprensión y traducción directa entre un lenguaje natural y de signos.

Además de esta complejidad multimodal, la naturaleza visual de la tarea presenta consideraciones relevantes en materia de privacidad. Procesar vídeos de personas requiere garantías sobre el tratamiento de datos personales, especialmente en entornos sensibles como la sanidad o la educación. Por ello, un enfoque que minimice la exposición de datos desde el origen resulta deseable. A raíz de esto nace la traducción de signos basados en *keypoints*, esto es puntos predeterminados en el cuerpo humano que resumen la información de la postura, expresión e información de manos, capturando la información gestual relevante sin preservar la identidad visual de la persona, permitiendo así un procesamiento más ligero, portable y respetuoso con la privacidad. De forma paralela, el uso de este enfoque, reduce drásticamente la dimensionalidad de los datos, optimizando los costes computacionales de entrenamiento e inferencia y facilitando su despliegue en equipos menos potentes.

1.3. Objetivo

Capítulo 2

Estado del Arte

Analizaremos en este capítulo el contexto general de la traducción de lengua de signos, desde su evolución hasta la actualidad. Finalmente estudiaremos el estado del arte específico a los modelos basados en *keypoints* y presentaremos los conjuntos de datos relevantes.

2.1. General (traducción en SL)

2.1.1. Modelos basados en Glosas

- STMC
- Transformers

2.1.2. Modelos *End2End*

- Gloss-Free SLT
- Sign2GPT (El Paradigma Gloss-based con LLM)

2.2. Uso de keypoints como entrada a modelos en SL

2.3. Datasets

El paradigma en cuanto conjuntos de datos no es muy diferente al de hace unos años. Esto radica principalmente en la dificultad y el coste que existe en la traducción manual de miles de videos de lengua de signos.

Capítulo 3

Metodología

Modelos que vamos a probar, preprocesado de datos (normalización, etc)

3.1. Extracción de Keypoints

Como se mencionó, la extracción de keypoints es el proceso mediante el cual se obtiene una representación estructurada del cuerpo humano a partir de imágenes o vídeo, en forma de coordenadas de puntos anatómicos predefinidos, tales como articulaciones, extremidades o rasgos faciales. Esta representación abstrae la información visual relevante para el movimiento y la postura, descartando información irrelevante como el fondo, la iluminación o la apariencia superficial, lo que la convierte en una representación compacta, generalizable y respetuosa con la privacidad, tal y como se argumentó en la sección anterior.

En los últimos años, el avance conjunto de la visión por computador y el aprendizaje profundo ha dado lugar a herramientas de estimación de pose de gran precisión y eficiencia. Entre las más destacadas se encuentran **MediaPipe Holistic**, desarrollada por Google y ampliamente adoptada en la literatura de lengua de signos por su capacidad para detectar simultáneamente cuerpo, manos y rostro en tiempo real con un bajo costo en recursos computacionales; **OpenPose**, uno de los primeros sistemas de estimación multi-persona de referencia; y **AlphaPose**, un sistema de estimación de pose de alta precisión que destaca especialmente en escenarios con múltiple personas, condiciones de oclusión y videos de baja calidad.

3.1.1. Alphapose

AlphaPose ha demostrado obtener el menor error medio en detección de keypoints frente a MediaPipe y OpenPose incluso bajo condiciones de degradación de imagen [1], lo que refuerza su idoneidad para entornos de grabación no controlados, habituales en datasets de lengua de signos, especialmente en el dataset con el que trabajaremos.




Figura 3.1: Keypoints en el Modelo Halpe-136

```
{  
  "version": "alphapose_halpe136",  
  "people": [{  
    "pose_keypoints_2d": [x0,y0,c0, x1,y1,c1, ...,  
      ↪ x135,y135,c135],  
    "box": [...],  
    "score": float  
  }]  
}
```

3.2. Seq2Seq

3.3. Normalización de los Datos

3.4. Métricas

3.5. Transformers

3.5.1. ¿Qué es un Transformer?

Capítulo 4

Experimentación y análisis de resultados

- 4.1. Ablation study
- 4.2. Comparativa con state of the art
- 4.3. También comparar la eficiencia

Capítulo 5

Conclusión y trabajo futuro

Bibliografía

- [1] NADA E. ELSHAMI, AHMAD SALAH, AMR ABDELLATIF Y HEBA MOHSEN, *Toward Robust Human Pose Estimation Under Real-World Image Degradations and Restoration Scenarios*, Information, vol. 16, no. 11, art. 970, 2025. Disponible en: <https://www.mdpi.com/2078-2489/16/11/970>
- [2] HAO-SHU FANG, JIEFENG LI, HONGYANG TANG, CHAO XU, HAOYI ZHU, YULIANG XIU, YONG-LU LI Y CEWU LU, *AlphaPose: Whole-Body Regional Multi-Person Pose Estimation and Tracking in Real-Time*, IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022. Disponible en: <https://github.com/Fang-Haoshu/Halpe-FullBody>