



**ESCUELA TÉCNICA SUPERIOR
DE
INGENIERIA INFORMÁTICA**

Trabajo Fin de Máster

Máster en Lógica, Computación, e Inteligencia Artificial

Sing2Text: Traducción basada en KeyPoints

Realizado por

Nicolás Rodríguez Ruiz

Tutorizado por

Miguel Ángel Martínez Del Amor

Departamento de

Ciencias de la Computación e Inteligencia Artificial

Sevilla, 21 de mayo de 2026

Índice general

1	Introducción	9
1.1	Resumen	9
1.2	Motivación y Planteamiento	9
1.3	Objetivo	10
2	Estado del Arte	11
2.1	General (traducción en SL)	11
2.1.1	Prediciendo con Glosas	11
2.1.2	Modelos <i>End2End</i>	13
2.1.3	LLMS para la traducción de signos	13
2.2	Uso de keypoints como entrada a modelos en SL	13
2.3	Datasets	13
3	Fundamentos	15
3.1	Medidas de precisión en traducción	15
3.2	Transformers	15
3.2.1	¿Por qué Transformers?	15
3.2.2	Codificación Posicional	16
3.2.3	Mecanismo de Auto-atención	16
4	Metodología	19
4.1	Extracción de Keypoints	19
4.1.1	Alphapose	20
4.2	Seq2Seq	22
4.3	Normalización de los Datos	22
4.4	Multi Stream Keypoint Attention	22

4.4.1	Data Augmentation	22
4.4.2	Arquitectura del Modelo de Reconocimiento	22
4.4.3	Arquitectura del Módulo de Traducción	22
5	Experimentación y análisis de resultados	23
5.1	Ablation study	23
5.2	Comparativa con state of the art	23
5.3	También comparar la eficiencia	23
6	Conclusión y trabajo futuro	25

Capítulo 1

Introducción

1.1. Resumen

1.2. Motivación y Planteamiento

Según los datos de la Organización Mundial de la Salud, más de 1,500 millones de personas en el mundo viven con algún grado de pérdida auditiva, de las cuales aproximadamente 430 millones requieren atención especializada. Para una parte significativa de esta población, la lengua de signos es su principal medio de comunicación natural. Sin embargo, el acceso a servicios esenciales como lo son la sanidad, la educación o la administración pública sigue dependiendo casi exclusivamente de intérpretes humanos, un recurso escaso, costoso y con disponibilidad geográfica muy desigual. Esta dependencia limita la autonomía de las personas sordas y perpetúa una brecha de inclusión social difícil de cerrar sin el apoyo de soluciones tecnológicas escalables.

En los últimos años ha habido enormes avances en las técnicas de *Procesamiento del Lenguaje Natural*, *Visión por Computador* y *Aprendizaje Profundo*, así como en la eficiencia y capacidad computacional de los equipos, sin embargo las lenguas de signos han recibido una atención comparativamente menor, y los avances no han alcanzado el nivel de madurez ni la cobertura lingüística que sí presentan los sistemas para lenguas orales. Los sistemas de traducción automática, los asistentes conversacionales y las interfaces de voz han transformado la forma en que las personas oyentes interactúan con la tecnología, pero siguen siendo inaccesibles para quienes se comunican mediante el canal viso-gestual.

Para abordar esta brecha, la investigación en traducción automática de lengua de signos se articula principalmente en torno a dos direcciones complementarias: por un lado, la traducción de texto o voz a lengua de signos, **Text2Sign**, orientada a facilitar la comprensión por parte de personas sordas; por otro, la traducción de lengua de signos a texto, **Sign2Text**, cuyo objetivo es permitir que las personas oyentes o los sistemas automáticos comprendan los mensajes signados. El presente trabajo se centra en esta

segunda dirección, **Sign2Text**, por su impacto directo en la autonomía comunicativa de las personas sordas y por los retos técnicos abiertos que aún presenta.

La tarea **Sign2Text**, también conocida como *Sign Language Recognition and Translation*, persigue la generación automática de texto a partir de una secuencia de signos capturada en vídeo. Un sistema de este tipo permitiría subtítular en tiempo real una conversación signada, dotar a los asistentes virtuales de la capacidad de entender a usuarios sordos, o facilitar el acceso a servicios públicos sin necesidad de un intérprete presente. En definitiva, actuaría como un puente de comunicación directo entre la comunidad sorda y los sistemas digitales diseñados, hasta ahora, pensando exclusivamente en usuarios oyentes.

Desde el punto de vista técnico, Sign2Text es un problema especialmente complejo. A diferencia del reconocimiento de voz, donde la señal de entrada es unidimensional y continua, la lengua de signos es inherentemente multimodal: la información se distribuye simultáneamente entre la configuración y el movimiento de las manos, la expresión facial, la postura corporal y el uso del espacio. Esta riqueza expresiva, que dota a las lenguas de signos de toda su potencia comunicativa, supone al mismo tiempo uno de los mayores desafíos para su modelado automático. A esto se le suma la gran variedad de lenguas de signos que existen, cada una con sus gestos y expresiones visuales únicas, además en la mayoría de los casos, la lengua de signos de una determinada región carece de relación gramatical con la lengua natural de dicha región. Esto dificulta significativamente la comprensión y traducción directa entre un lenguaje natural y de signos.

Además de esta complejidad multimodal, la naturaleza visual de la tarea presenta consideraciones relevantes en materia de privacidad. Procesar vídeos de personas requiere garantías sobre el tratamiento de datos personales, especialmente en entornos sensibles como la sanidad o la educación. Por ello, un enfoque que minimice la exposición de datos desde el origen resulta deseable. A raíz de esto nace la traducción de signos basados en *keypoints*, esto es puntos predeterminados en el cuerpo humano que resumen la información de la postura, expresión e información de manos, capturando la información gestual relevante sin preservar la identidad visual de la persona, permitiendo así un procesamiento más ligero, portable y respetuoso con la privacidad. De forma paralela, el uso de este enfoque, reduce drásticamente la dimensionalidad de los datos, optimizando los costes computacionales de entrenamiento e inferencia y facilitando su despliegue en equipos menos potentes.

1.3. Objetivo

Capítulo 2

Estado del Arte

Analizaremos en este capítulo el contexto general de la traducción de lengua de signos, desde su evolución hasta la actualidad. Finalmente estudiaremos el estado del arte específico a los modelos basados en *keypoints* y presentaremos los conjuntos de datos relevantes.

2.1. General (traducción en SL)

Como vimos en la introducción, la traducción automática de la lengua de signos es un problema complejo que implica mapear una secuencia de vídeo continuo a una secuencia de texto en un lenguaje hablado, superando grandes barreras espaciales, sintácticas y gramaticales. A lo largo de los últimos años ha habido grandes avances en las técnicas utilizadas. De similar forma a las tareas de traducción tradicionales se han preferido arquitecturas basadas en mecanismos de atención, *vision transformers* o incluso *LLM*.

2.1.1. Prediciendo con Glosas

Muchos de los intentos más exitosos y el paradigma hace unos años era utilizar las glosas como representación intermedia para la traducción. Este enfoque de dos etapas simplificaba el problema, pero sufría del cuello de botella de la propagación de errores. Esto es, cuando la parte del modelo encargada de traducir las glosas comete un error, la segunda parte, por muy buena que sea, al tener información equivocada cometerá un error en la traducción.

STMC (Spatial-Temporal Multi-Cue, SLR)

Aunque la lingüística ya reconocía el carácter fundamentalmente multimodal de la lengua de signos, los modelos STMC (Spatial-Temporal Multi-Cue) fueron pioneros en

integrar esta premisa directamente en el diseño arquitectónico de una red neuronal entrenable de principio a fin. A diferencia de enfoques anteriores que dependían de algoritmos externos (como rastreadores de manos) o que simplemente concatenaban características perdiendo información, las redes **STMC**, propuestas por Zhou et al. [7] en 2020, procesan de forma conjunta diferentes señales visuales (forma de las manos, expresiones faciales, postura corporal) en dimensiones espaciales y temporales para mejorar el reconocimiento de glosas. Para lograr esto, la arquitectura del modelo se divide en dos componentes principales:

- **Módulo Espacial Multiseñal (*Spatial Multi-Cue*)** que se encarga de la representación espacial en cada fotograma. Incorpora una rama de estimación de pose integrada y diferenciable que permite recortar y extraer automáticamente las características visuales específicas de cada canal.
- **Módulo Temporal Multiseñal (*Temporal Multi-Cue*)** que modela las dependencias temporales a lo largo del video a través de dos rutas paralelas. La ruta intra-señal preserva las características únicas y la evolución temporal de cada canal de forma aislada, mientras que la ruta inter-señal explora la sinergia y colaboración entre todas las señales a diferentes escalas de tiempo.




Figura 2.1: Estructura del modelo STMC

Spotter+GPT (Traducción Híbrida de SLT)

Aunque la traducción de la lengua de signos se ha formulado frecuentemente como una tarea de traducción automática neuronal compleja debido a los desafíos para alinear y tokenizar videos, además de las marcadas diferencias gramaticales entre lenguajes hablados y de signos, el enfoque propuesto por Sincan et al. [?] en 2024 innova al prescindir del entrenamiento de un modelo de traducción glosa-a-texto. A diferencia de los enfoques convencionales que pueden presentar un bajo rendimiento en dominios extensos, el método **Spotter+GPT** propone una arquitectura híbrida que combina el reconocimiento visual clásico con las capacidades de razonamiento de un **LLM** preentrenado. Para lograr esto, la arquitectura del sistema se divide en dos componentes principales:

- **Módulo de Detección Visual (*Sign Spotter*)** que utiliza un modelo I3D entrenado con un gran conjunto de datos de dominio lingüístico para identificar signos individuales. Este módulo procesa el video continuo mediante una técnica de ventana deslizante para extraer predicciones de glosas, aplicando posteriormente un filtrado basado en umbrales de confianza para consolidar la secuencia.

- **Módulo de Generación de Lenguaje (*ChatGPT* / *LLM*)** que emplea la versión *gpt-3.5-turbo* para recibir la secuencia de glosas detectadas de forma directa. Mediante ingeniería de instrucciones (*prompting*) y sin requerir ajuste fino (*fine-tuning*), el modelo transforma esta lista en una oración coherente en lenguaje hablado, superando de forma dinámica las diferencias en el orden gramatical.




Figura 2.2: Estructura del modelo spotter+GPT

En cuanto a los resultados, los experimentos muestran que el Spotter+GPT supera a modelos secuenciales dedicados en métricas de calidad humana y similitud semántica (como BLEURT). Además, destaca cualitativamente por su gran resiliencia, logrando mantener la coherencia semántica en la oración hablada final incluso cuando el detector visual pierde información o introduce glosas adicionales.

- Transformers

2.1.2. Modelos *End2End*

- Gloss-Free SLT
- Sign2GPT (El Paradigma Gloss-based con LLM)

2.1.3. LLMS para la traducción de signos

2.2. Uso de keypoints como entrada a modelos en SL

2.3. Datasets

El paradigma en cuanto conjuntos de datos no es muy diferente al de hace unos años. Esto radica principalmente en la dificultad y el coste que existe en la traducción manual de miles de videos de lengua de signos.

Capítulo 3

Fundamentos

3.1. Medidas de precisión en traducción

3.2. Transformers

La aparición de la arquitectura **transformer**, introducida por **Vaswani et al.** [3], supuso un cambio de paradigma en el procesamiento de secuencias, desplazando a las redes recurrentes en tareas de modelado de lenguaje. La relevancia de este modelo en el presente trabajo radica en su capacidad para gestionar dependencias de largo alcance mediante el mecanismo de auto-atención (*self-attention*), el cual permite que cada elemento de una secuencia (ya sea una palabra o un *keypoint* del cuerpo) sea procesado en relación con todos los demás de forma paralela. Por ello, dedicaremos esta sección a entender el funcionamiento de los *transformers* con cierto nivel de detalle.

3.2.1. ¿Por qué Transformers?

Para entender la relevancia e innovación de los transformers es necesario conocer lo que les precedía. En particular, las *long short-term memory* y las *gated recurrent neural networks* dominaron el procesamiento de secuencias mediante mecanismos de computación recurrente, los cuales procesan la información de manera secuencial siguiendo el orden temporal de la entrada. Estas arquitecturas presentaban dos limitaciones fundamentales: la dificultad para captar dependencias de largo alcance debido al desvanecimiento del gradiente y la imposibilidad de paralelizar el entrenamiento, lo que restringe enormemente la eficiencia computacional con secuencias largas.

Los transformers proponen abandonar por completo la recurrencia en favor del mecanismo de atención, lo que les permite captar dependencias de largo alcance en los textos de forma directa y con operaciones fácilmente paralelizables. En lugar de procesar la secuencia elemento a elemento, estos modelos consideran simultáneamente todos los tokens

de entrada mediante el mecanismo de auto-atención, que calcula la relevancia relativa entre cada par de posiciones de la secuencia.

Este enfoque introduce varias ventajas clave. En primer lugar, elimina la dependencia estrictamente secuencial del cómputo, permitiendo un uso mucho más eficiente del hardware moderno, especialmente en arquitecturas paralelas como las **GPUs**. En segundo lugar, facilita el modelado de relaciones a larga distancia sin los problemas asociados al desvanecimiento del gradiente, ya que cualquier elemento de la secuencia puede interactuar directamente con cualquier otro en un solo paso de atención.

Además, los transformers incorporan mecanismos como las codificaciones posicionales para preservar la información sobre el orden de la secuencia, compensando así la ausencia de recurrencia. Esta combinación de atención global y representación posicional ha demostrado ser altamente efectiva en tareas de modelado del lenguaje y traducción automática, superando ampliamente a las arquitecturas recurrentes tradicionales.

Es natural plantearse si esta habilidad y facilidad que presentan los transformers en la traducción de lenguajes se translada a la lengua de signos utilizando los *keypoints* como representación de los signos.

3.2.2. Codificación Posicional

3.2.3. Mecanismo de Auto-atención

La función de atención es un mecanismo que permite a un modelo identificar y priorizar la información más relevante dentro de un conjunto de datos. Para ello, compara una consulta, *query* con un conjunto de claves, *keys*, mediante una función de compatibilidad, que mide qué tan bien coincide la *query* con cada *key*, generando pesos que reflejan la importancia de cada elemento. Transformando estos pesos en una distribución de probabilidad mediante la función *softmax*, se calcula una combinación ponderada de los valores *values*, produciendo así una representación que enfatiza los componentes más pertinentes.

La función de atención más relevante es la *Scaled Dot-Product Attention* cuya entrada son claves y consultas de dimensión d_k y valores de dimensión d_v . En la práctica, sacando provecho de que la multiplicación entre matrices está muy optimizada, estas operaciones se hacen mediante matrices, obteniendo la siguiente fórmula.

$$Attention(Q, K, V) = softmax\left(\frac{QK'}{\sqrt{d_k}}\right) V.$$

Se añade el factor de escalado $\sqrt{d_k}$, pues si las matrices de *query* y *key* son de una muy alta dimensión, es posible que los valores exploten en tamaño, donde la función *softmax* se vuelve muy “extrema”, es decir, asigna casi todo el peso a un solo elemento y hace que los gradientes sean muy pequeños, dificultando el entrenamiento.




Figura 3.1: Una cabeza de atención

Un problema que surge es la limitada capacidad de una sola cabeza de prestar atención a multiples aspectos de la entrada, pues al tratar de hacerlo se diluyen las relaciones al mezclarse, potencialmente limitando la capacidad de comprensión del modelo.

Así, en vez de tener una única función de atención con *keys*, *values* y *queries* d_{modelo} -dimensionales, **Vaswani et al.** proponen utilizar h diferentes proyecciones lineales a dimensión d_k , para consultas y claves, y d_v para valores. De esta forma el modelo puede “prestar atención” a distintos aspectos de la entrada de forma simultánea.

En este caso, la atención multi-cabeza se calcula como sigue

$$MultiHead(Q, K, V) = Concat(head_1, head_2, \dots, head_h)W^O$$

$$\text{con } head_i = Attention(QW_i^Q, KW_i^K, VW_i^V),$$

donde $W_i^Q, W_i^K \in \mathbb{R}^{d_{\text{modelo}} \times d_k}$, $W_i^V \in \mathbb{R}^{d_{\text{modelo}} \times d_v}$ y $W^O \in \mathbb{R}^{hd_v \times d_{\text{modelo}}}$ son matrices de pesos entrenables. En particular las matrices W son las proyecciones.




Figura 3.2: Diagrama de la atención multi-cabeza

Capítulo 4

Metodología

Modelos que vamos a probar, preprocesado de datos (normalización, etc)

4.1. Extracción de Keypoints

Como se mencionó, la extracción de keypoints es el proceso mediante el cual se obtiene una representación estructurada del cuerpo humano a partir de imágenes o vídeo, en forma de coordenadas de puntos anatómicos predefinidos, tales como articulaciones, extremidades o rasgos faciales. Esta representación abstrae la información visual relevante para el movimiento y la postura, descartando información irrelevante como el fondo, la iluminación o la apariencia superficial, lo que la convierte en una representación compacta, generalizable y respetuosa con la privacidad, tal y como se argumentó en la sección anterior.

En los últimos años, el avance conjunto de la visión por computador y el aprendizaje profundo ha dado lugar a herramientas de estimación de pose de gran precisión y eficiencia. Entre las más destacadas se encuentran **MediaPipe Holistic**, desarrollada por Google y ampliamente adoptada en la literatura de lengua de signos por su capacidad para detectar simultáneamente cuerpo, manos y rostro en tiempo real con un bajo coste computacional.

OpenPose, uno de los primeros sistemas de estimación de pose multi-persona de referencia, ha sido ampliamente utilizado en trabajos previos; sin embargo, presenta limitaciones en términos de eficiencia y robustez frente a enfoques más recientes.

Por otro lado, métodos como **HRNet**, mediante **MMPose**, ofrecen una elevada precisión en la localización de keypoints en imágenes estáticas gracias a su arquitectura de alta resolución, aunque no incorporan de forma explícita mecanismos de modelado temporal, lo que puede generar variabilidad entre frames en secuencias de vídeo.

Finalmente, **AlphaPose** es un sistema de estimación de pose de alta precisión que destaca especialmente en escenarios multi-persona, condiciones de oclusión y vídeos de

baja calidad, lo cual resulta especialmente relevante para nuestro caso de uso. Además, a diferencia de HRNet en sus configuraciones más pesadas, AlphaPose está optimizado para un mejor compromiso entre precisión y velocidad, permitiendo una extracción más eficiente en entornos prácticos.

4.1.1. Alphapose

Como mencionamos AlphaPose ha demostrado obtener el menor error medio en detección de keypoints frente otras herramientas especialmente bajo condiciones de degradación de imagen, [1], lo que refuerza su idoneidad para entornos de grabación no controlados, habituales en datasets de lengua de signos, particularmente en el *dataset* con el que trabajaremos.

AlphaPose ofrece la capacidad de cambiar el modelo utilizado para la representación del esqueleto, existiendo principalmente dos conjuntos de datos de pose de cuerpo completo:

- **COCO-WholeBody**, una ampliación del conjunto de datos **MS COCO** enfocada en el cuerpo humano completo. Incluye anotaciones detalladas de puntos clave del cuerpo, manos, cara y pies, lo que permite realizar estimaciones de pose más completas y precisas en tareas de análisis del movimiento humano.
- **HALPE-136**, un conjunto de datos más reciente que proporciona una anotación aún más densa (136 puntos clave), con especial énfasis en manos y rostro. Este mayor nivel de detalle puede resultar beneficioso en tareas que requieren capturar movimientos finos, como el reconocimiento de lengua de signos, aunque a costa de una mayor complejidad computacional y posible sensibilidad al ruido en entornos no controlados.




Figura 4.1: Keypoints en el Modelo Halpe-136

```

{
  "version": "alphapose_halpe136",
  "people": [{
    "pose_keypoints_2d": [x0,y0,c0, x1,y1,c1, ...,
      ↪ x135,y135,c135],
    "box": [...],
    "score": float
  }]
}

```

4.2. Seq2Seq

4.3. Normalización de los Datos

4.4. Multi Stream Keypoint Attention

En esta sección se presentará la arquitectura principal del modelo *Multi-stream Keypoint Attention* (MSKA) detallando el razonamiento detrás de la misma. Es importante notar que este modelo **no** es *end-to-end*, hace uso de las glosas como representación intermedia de la traducción, asegurando que el modelo realmente aprende el significado detrás de los *keypoints*.

4.4.1. Data Augmentation

4.4.2. Arquitectura del Modelo de Reconocimiento

Desacoplamiento de Keypoints

Módulo de Atención de Keypoints

Redes de Cabecera (*Head Networks*) y Fusión

Aprendizaje por Auto-destilación

Función de Pérdida de Reconocimiento

4.4.3. Arquitectura del Módulo de Traducción

Capítulo 5

Experimentación y análisis de resultados

- 5.1. Ablation study
- 5.2. Comparativa con state of the art
- 5.3. También comparar la eficiencia

Capítulo 6

Conclusión y trabajo futuro

Bibliografía

- [1] NADA E. ELSHAMI, AHMAD SALAH, AMR ABDELLATIF Y HEBA MOHSEN, *Toward Robust Human Pose Estimation Under Real-World Image Degradations and Restoration Scenarios*, Information, vol. 16, no. 11, art. 970, 2025. Disponible en: <https://www.mdpi.com/2078-2489/16/11/970>
- [2] HAO-SHU FANG, JIEFENG LI, HONGYANG TANG, CHAO XU, HAOYI ZHU, YULIANG XIU, YONG-LU LI Y CEWU LU, *AlphaPose: Whole-Body Regional Multi-Person Pose Estimation and Tracking in Real-Time*, IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022. Disponible en: <https://github.com/Fang-Haoshu/Halpe-FullBody>
- [3] ASHISH VASWANI, NOAM SHAZEER, NIKI PARMAR, JAKOB USZKOREIT, LLION JONES, AIDAN N. GOMEZ, LUKASZ KAISER E ILLIA POLOSUKHIN, *Attention Is All You Need*, arXiv preprint, art. 1706.03762, 2023. Disponible en: <https://arxiv.org/abs/1706.03762>
- [4] HAO-SHU FANG, JIEFENG LI, HONGYANG TANG, CHAO XU, HAOYI ZHU, YULIANG XIU, YONG-LU LI Y CEWU LU, *AlphaPose: Whole-Body Regional Multi-Person Pose Estimation and Tracking in Real-Time*, IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022.
- [5] HAO-SHU FANG, SHUQIN XIE, YU-WING TAI Y CEWU LU, *RMPE: Regional Multi-person Pose Estimation*, Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017.
- [6] JIEFENG LI, CAN WANG, HAO ZHU, YIHUAN MAO, HAO-SHU FANG Y CEWU LU, *Crowdpose: Efficient crowded scenes pose estimation and a new benchmark*, Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), pp. 10863-10872, 2019.
- [7] HAO ZHOU, WENGANG ZHOU, YUN ZHOU Y HOUQIANG LI, *Spatial-Temporal Multi-Cue Network for Continuous Sign Language Recognition*, CoRR, vol. abs/2002.03187, 2020. Disponible en: <https://arxiv.org/abs/2002.03187>