

Traducción de lengua de signos basada en *keypoints* con modelos pequeños del lenguaje

Nicolás Rodríguez Ruiz

Departamentp de Ciencias de la Computación e Inteligencia Artificial
ESCUELA TÉCNICA SUPERIOR DE INGENIERIA INFORMÁTICA

July 8, 2026

1. Motivación y objetivos
2. Estado del arte
3. Fundamentos
4. Metodología
5. Experimentación y resultados
6. Conclusiones y trabajo futuro

El reto de la comunicación

> 1 500 M

personas con pérdida auditiva (OMS)




La lengua de signos es el medio natural de millones de personas, pero el acceso a servicios esenciales aún depende de un recurso escaso.

Dos direcciones, un mismo objetivo: la inclusión



- **Text2Sign:** generar signos para la comprensión de personas sordas.
- **Sign2Text:** comprender los signos → **impacto directo en la autonomía comunicativa.**


Sign2Text: del vídeo al texto



¿Qué habilita?

Subtitulado en tiempo real · asistentes que entienden a usuarios sordos · servicios públicos sin intérprete presente.


¿Por qué es difícil? Una señal multimodal



A diferencia del habla (señal 1D), la información se distribuye en varios canales a la vez.


- Gran **variedad** de lenguas de signos.
- Normalmente **sin relación gramatical** con la lengua oral de la región.

Keypoints: privacidad y eficiencia



Vídeo (píxeles)
identidad visible

estimación
de pose →



Keypoints
sin identidad


- ✓ Privacidad (no reidentificable)
- ✓ Menor dimensionalidad
- ✓ Ligero y portable

Puntos predefinidos del cuerpo que capturan el gesto **sin preservar la identidad visual** y reducen drásticamente la dimensionalidad.

Objetivo principal

Meta

Demostrar la viabilidad de un sistema **Sign2Text** basado en representaciones intermedias (**glosas** y **keypoints**) mediante un **Modelo Pequeño de Lenguaje** *decoder-only*, manteniendo **ejecución local** y **privacidad**.




ejecución local · privacidad · razonamiento contextual

Objetivos específicos


- 1 Reimplementar **MSKA** como línea base (PHOENIX-2014T)
- 2 Diseñar el **VLMapper**: alinear visión $\rightarrow$ *embeddings* del SLM
- 3 Traducción **zero-shot** sobre glosas (paradigma Spotter+GPT)
- 4 Adaptar con **LoRA**: features vs. glosas, con/sin prompt
- 5 Escalado del **SLM**: Qwen2.5-1.5B vs. 7B
- 6 Coste computacional: parámetros entrenables y memoria GPU

Una evolución de arquitecturas



Del *hardware* intrusivo y las reglas manuales al razonamiento contextual; el reconocimiento pasa de **aislado** a **continuo**, más cercano a la comunicación real.

Con glosas frente a sin glosas



- **Dos etapas:** las glosas dan estructura, pero **propagan errores** y exigen anotación experta.
- **Una etapa:** elimina el cuello de botella, pero se **estanca** por la escasez de datos.

El renacer de las glosas con LLMs: Spotter+GPT



El LLM **razona** sobre glosas imperfectas sin entrenamiento específico


LLM

El LLM tolera glosas ruidosas *zero-shot*: BLEURT 46.9 vs. 19.9 del *transformer*.

Límites para el despliegue

Nube, coste de API, **privacidad** y latencia
→ inviable en tiempo real y local.

Keypoints y MSKA: el hueco que motiva el SLM



MSKA desacopla manos, rostro y cuerpo en flujos de atención, pero lo acopla a un decodificador **mBART** rígido: aquí entra nuestro **Modelo Pequeño de Lenguaje**.


Conjuntos de datos: por qué PHOENIX-2014T

Corpus	Lengua	Dominio	Keypoints	Acceso
PHOENIX-2014T	DGS (alemán)	Meteorología	No	Público
CSL-Daily	CSL (chino)	Cotidiano	No	Restringido
How2Sign	ASL (inglés)	Instructivo	Sí (2D)	Público
LSE-eSaude	LSE (español)	Salud	No	Público

Elección

Estándar de oro (comparabilidad con casi una década de literatura), **corpus original de MSKA** (base de referencia exacta) y **acceso público** (reproducibilidad).

Métricas: de lo léxico a lo semántico




- **WER** mide el error sobre las **glosas** (reconocimiento).
- BLEU y ROUGE-L comparan **coincidencia léxica**; **BLEURT** valora el **significado** (sinónimos y paráfrasis).

Transformer y modelos *decoder-only*

Adaptación eficiente: LoRA

$$W = W_0 + \frac{\alpha}{r} BA$$



solo se entrenan A y B

El esqueleto como dato: alineación con CTC



Muchas rutas → el mismo resultado:

Ruta A: [HOLA, HOLA, -, -, -]


Ruta B: [-, HOLA, HOLA, -, -]

Ruta C: [-, -, -, HOLA, HOLA]

la CTC suma todas las alineaciones válidas


La secuencia de *keypoints* es mucho más larga que la de glosas y no está segmentada. **CTC** alinea ambas sumando todas las rutas válidas, sin anotar el instante exacto de cada signo.

DSTA: atención espacio-temporal desacoplada



Separar el modelado **espacial** (entre articulaciones) del **temporal** (a lo largo del tiempo) abarata el cómputo y respeta la estructura del esqueleto. Es el bloque base de **MSKA**.


DSTA: tres estrategias de desacoplamiento



- (a) un mapa por fotograma: sin contexto global.
- (b) un mapa entre todos los fotogramas: potente pero **muy costoso**.
- (c) suma los mapas por fotograma $\rightarrow$ un **único producto** $N \times N$: mismo resultado, mucho más eficiente.


DSTA: codificación posicional espacial y temporal

PE espacial



Espacial: la misma articulación conserva su identidad en todo fotograma.


PE temporal



Temporal: se codifica el instante; dentro del fotograma no varía.


Una PE ingenua sobre el tensor aplanado daría a la misma articulación códigos dispares en distintos fotogramas; **separar espacio y tiempo** preserva la semántica del esqueleto.

DSTA: el módulo de atención espacial



- **SGR:** mapa global entrenable $N \times N$ que aporta la anatomía (constante entre sujetos), solo en la dimensión espacial.
- **Tanh** en lugar de *softmax*: permite relaciones **negativas** entre articulaciones. S cabezas y conexiones residuales.

DSTA-Net: la estructura completa



Cada una de las L capas encadena **atención espacial** $\rightarrow$ **transposición** $\rightarrow$ **atención temporal**.
Es el bloque que MSKA adapta por cada flujo de *keypoints*.

Visión general del sistema



Un flujo de **tres etapas**: extracción de *keypoints* (AlphaPose), reconocimiento de **glosas** (MSKA-SLR) y **traducción** (VLMapper + SLM). Las secciones siguen este orden.

Extracción de *keypoints*: ¿qué herramienta?

Herramientas de estimación de pose

OpenPose

F1 MPIO
83.67%

superado en
precisión y
coste elevado

MediaPipe

muy rápido
optimizado a
una persona;
pierde el foco
con fondo caótico

MMPose

F1 MPIO
87.12%

fotograma a
fotograma
⇒ *jittering*
temporal


AlphaPose

ELEGIDO

maduro y
comparable
seguimiento de
vídeo nativo
(*Pose Flow*)

El dominio exige **coherencia temporal** y robustez con varias personas en escena. Elegimos **AlphaPose**: maduro, comparable con la literatura y con **seguimiento de vídeo nativo**.

AlphaPose: enfoque *top-down* y robustez



Mecanismos nativos frente a oclusión y ruido:


SSTN: recentra la silueta
si la caja se desvió

p-Pose NMS: elimina
extremidades duplicadas


Pose Flow: continuidad
temporal ante desenfoque

La estrategia **descendente** (RMPE) detecta primero a cada persona y luego estima su pose,
blindando al signante frente al ruido del entorno.

El dilema del *jittering*: no suavizar



Normalización de los datos espaciales




El canal de confianza
 $c \in [0, 1]$ **no se modifica**



Independencia de la resolución y estabilidad numérica: se lleva todo al rango $[-1, 1]$ con el **torso** (referencia global) mapeado al origen.

Aumento de datos: combatir la escasez

Rotación $\pm 15^\circ$



Aumento temporal



Joint Dropout




Ruido gaussiano




$\mathcal{N}(0, 0.01^2)$ sobre cada punto

MSKA-SLR: cuatro flujos desacoplados




Dentro del flujo: módulo de atención de *keypoints*




- Codificación posicional **solo espacial**; el tiempo se modela con **convoluciones 2D** → menos parámetros, menos sobreajuste.
- Cascada de **8 bloques** que contrae $T \rightarrow T/4$ y expande los canales hasta 256.

Redes de cabecera y fusión



Cada flujo tiene su cabecera (produce la **representación de glosa**, $T/4 \times 512$), y un **Cabezal de Fusión** integra los cuatro. En inferencia sus probabilidades se promedian en un *ensemble*.

Pérdida: CTC más autodestilación




$$\mathcal{L}_{Dist} = \sum_s D_{KL}(\bar{P} \parallel P^s)$$

Cada cabeza se supervisa con **CTC**. Además, el promedio del *ensemble* actúa como **pseudo-objetivo**: la divergencia **KL** acerca cada flujo al conocimiento global.

Stop-gradient


El promedio es un **ancla estática**; evita el colapso del modelo.

Del reconocimiento a la traducción: de mBART al SLM



En lugar del **mBART** rígido, proyectamos la representación de glosa con el **VLMapper** y la anteponemos como **prefijo visual** a un SLM *decoder-only*, aprovechando su razonamiento contextual.

Adaptación eficiente: VLMapper, LoRA y zero-shot



La pérdida se aplica **solo sobre la traducción**. Se congela Qwen y se entrenan el **VLMapper** ($\approx 0.5\text{--}1.8$ M par.) y los adaptadores **LoRA**.

Zero-shot

Como **Spotter+GPT**: pasar las glosas como texto a Qwen2.5-14B sin entrenar, como línea base.

■ Qwen congelado ★ VLMapper + LoRA entrenables

Configuración experimental

Entorno

- 1× **NVIDIA A100** (40 GB), bfloat16.
- PyTorch + *Transformers* (Hugging Face).
- Optimizador **AdamW**, *cosine decay*, *early stopping*.

LoRA

- Rango $r = 64$, $\alpha = 128 \Rightarrow$ escala $\alpha/r = 2$, *dropout* 0.25.
- **LoRA-Att**: solo atención. **LoRA-All**: + FFN.
- Qwen congelado; *Full* solo viable en 1.5B.

Evaluación sobre **PHOENIX-2014T**: reconocimiento con **WER** y traducción con **BLEU** y **ROUGE-L** (más **BLEURT** en *zero-shot*).

El corpus PHOENIX-2014T de un vistazo

7 096

muestras de
entrenamiento

116.5

frames por
vídeo (media)

23.6

tokens por
frase (media)

1 094

glosas en el
vocabulario

Percentil 99 = 51 tokens $\Rightarrow$ justifica `max_new_tokens=`
51 · ~ 5 *frames*/token $\Rightarrow$ `clip_len=` 400

Corpus **pequeño** y de dominio acotado (meteorología): la escasez de datos será el hilo conductor del análisis.


Reconocimiento (SLR): estudio de aumento de datos

Configuración	Dev WER↓	Test WER↓	SUB	DEL	INS
SLR-base	27.81	27.33	11.81	13.29	2.23
SLR-JointDropout	27.68	27.24	12.28	12.51	2.44
SLR-StructuredDropout	28.24	27.59	12.82	12.21	2.56
SLR-GaussianNoise	28.56	28.13	12.82	13.15	2.16

El aumento apenas ayuda (< 0.1 pts de WER). **Joint Dropout**, la variante más suave, gana por poco: reduce **eliminaciones** a costa de más sustituciones.

SLR: sobreajuste y análisis cualitativo

Comparativa de Modelos SLR



Brecha persistente entrenamiento (~ 15) vs. validación (~ 45): el **corpus reducido** es la limitación, no la regularización. Errores como *AUFLOESEN* $\rightarrow$ *VERSCHWINDEN* (sinónimos) **motivan un LLM** en la traducción.

Traducción: la línea base mBART

Modelo	B1	B2	B3	B4	ROUGE-L
MSKA-mBART (test)	45.03	34.51	27.43	22.48	45.00

Referencia sólida

BLEU-4 de **22.48** coherente con la literatura (valida nuestra reimplementación). Su arquitectura *encoder-decoder* con **preentrenamiento multilingüe** en alemán generaliza bien: Dev y Test casi idénticos.

Traducción *zero-shot*: Spotter + Qwen-14B

BLEU-4 = 0.46 · ROUGE-L = 9.85 · **BLEURT** = 0.50 (vs. 0.49 de Spotter+GPT con glosas ruidosas).

Escasez de glosas

Secuencias cortas → responde
"Keine Übersetzung".

Rompe la instrucción


Añade comentarios en lugar de traducir.

Alucinación multilingüe

Genera texto en **chino** a mitad de la respuesta.

La brecha con mBART justifica el *finetuning*.

Ablación (Qwen-1.5B): modalidad de entrada y LoRA




Visuales y glosas rinden **similar** con la LoRA adecuada.

El colapso

Visual + LoRA-All se hunde a **10.73**. No es la capacidad: es la **interferencia del prompt**.


Hallazgo: el *prompt* es contraproducente



Con *finetuning*, el modelo se condiciona directamente sobre los **tokens visuales**. El *prompt* textual **compite** con ellos por la atención y actúa como ruido.

Eliminarlo recupera casi **10 puntos** de BLEU-4 → mejor configuración de 1.5B (**20.55**).


Escalado: el tamaño importa más que la estrategia




7B (LoRA) supera al Full de 1.5B con 40× menos parámetros entrenados

Qwen-7B con LoRA-Att (20.03) supera al *finetuning* completo de 1.5B (18.68): con datos escasos, la **capacidad del modelo base** manda.

Comparativa global



Coste computacional: la relación rendimiento–coste



mBART entrena **657 M** de parámetros;
Qwen-7B LoRA-Att solo **40 M**.

Punto óptimo

Con $\sim 2.2\times$ la memoria de 1.5B, el 7B logra +3.72 BLEU-4: la mayor ganancia por coste de toda la batería.

Gracias por su tiempo