

Traducción de lengua de signos basada en *keypoints* con modelos pequeños del lenguaje

Nicolás Rodríguez Ruiz

Departamentp de Ciencias de la Computación e Inteligencia Artificial
ESCUELA TÉCNICA SUPERIOR DE INGENIERIA INFORMÁTICA

July 7, 2026

1. Motivación y objetivos
2. Estado del arte
3. Fundamentos
4. Metodología
5. Experimentación y resultados
6. Conclusiones y trabajo futuro

El reto de la comunicación

> 1 500 M

personas con pérdida auditiva (OMS)




La lengua de signos es el medio natural de millones de personas, pero el acceso a servicios esenciales aún depende de un recurso escaso.

Dos direcciones, un mismo objetivo: la inclusión



- **Text2Sign**: generar signos para la comprensión de personas sordas.
- **Sign2Text**: comprender los signos → **impacto directo en la autonomía comunicativa.**


Sign2Text: del vídeo al texto



¿Qué habilita?

Subtitulado en tiempo real · asistentes que entienden a usuarios sordos · servicios públicos sin intérprete presente.


¿Por qué es difícil? Una señal multimodal



A diferencia del habla (señal 1D), la información se distribuye en varios canales a la vez.


- Gran **variedad** de lenguas de signos.
- Normalmente **sin relación gramatical** con la lengua oral de la región.

Keypoints: privacidad y eficiencia



Vídeo (píxeles)
identidad visible

estimación
de pose



Keypoints
sin identidad


- ✓ Privacidad (no reidentificable)
- ✓ Menor dimensionalidad
- ✓ Ligero y portable

Puntos predefinidos del cuerpo que capturan el gesto **sin preservar la identidad visual** y reducen drásticamente la dimensionalidad.

Objetivo principal

Meta

Demostrar la viabilidad de un sistema **Sign2Text** basado en representaciones intermedias (**glosas** y **keypoints**) mediante un **Modelo Pequeño de Lenguaje** *decoder-only*, manteniendo **ejecución local** y **privacidad**.




ejecución local · privacidad · razonamiento contextual

Objetivos específicos


- 1 Reimplementar **MSKA** como línea base (PHOENIX-2014T)
- 2 Diseñar el **VLMapper**: alinear visión $\rightarrow$ *embeddings* del SLM
- 3 Traducción **zero-shot** sobre glosas (paradigma Spotter+GPT)
- 4 Adaptar con **LoRA**: features vs. glosas, con/sin prompt
- 5 Escalado del **SLM**: Qwen2.5-1.5B vs. 7B
- 6 Coste computacional: parámetros entrenables y memoria GPU

Una evolución de arquitecturas



Del *hardware* intrusivo y las reglas manuales al razonamiento contextual; el reconocimiento pasa de **aislado** a **continuo**, más cercano a la comunicación real.

Con glosas frente a sin glosas



- **Dos etapas:** las glosas dan estructura, pero **propagan errores** y exigen anotación experta.
- **Una etapa:** elimina el cuello de botella, pero se **estanca** por la escasez de datos.

El renacer de las glosas con LLMs: Spotter+GPT



El LLM **razona** sobre glosas imperfectas sin entrenamiento específico


LLM

El LLM tolera glosas ruidosas *zero-shot*: BLEURT 46.9 vs. 19.9 del *transformer*.

Límites para el despliegue

Nube, coste de API, **privacidad** y latencia
→ inviable en tiempo real y local.

Keypoints y MSKA: el hueco que motiva el SLM



MSKA desacopla manos, rostro y cuerpo en flujos de atención, pero lo acopla a un decodificador **mBART** rígido: aquí entra nuestro **Modelo Pequeño de Lenguaje**.


Conjuntos de datos: por qué PHOENIX-2014T

Corpus	Lengua	Dominio	Keypoints	Acceso
PHOENIX-2014T	DGS (alemán)	Meteorología	No	Público
CSL-Daily	CSL (chino)	Cotidiano	No	Restringido
How2Sign	ASL (inglés)	Instructivo	Sí (2D)	Público
LSE-eSaude	LSE (español)	Salud	No	Público

Elección

Estándar de oro (comparabilidad con casi una década de literatura), **corpus original de MSKA** (base de referencia exacta) y **acceso público** (reproducibilidad).

Métricas: de lo léxico a lo semántico




- **WER** mide el error sobre las **glosas** (reconocimiento).
- BLEU y ROUGE-L comparan **coincidencia léxica**; **BLEURT** valora el **significado** (sinónimos y paráfrasis).

Transformer y modelos *decoder-only*

La **autoatención** relaciona cada elemento con todos en paralelo. Un LLM **decoder-only** prescinde del codificador y genera texto de forma autorregresiva; su escalado produce **capacidades emergentes** (*zero-shot*).

Adaptación eficiente: LoRA

$$W = W_0 + \frac{\alpha}{r} BA$$



solo se entrenan A y B

El esqueleto como dato: alineación con CTC



Muchas rutas → el mismo resultado:

Ruta A: [HOLA, HOLA, -, -, -]


Ruta B: [-, HOLA, HOLA, -, -]

Ruta C: [-, -, -, HOLA, HOLA]

la CTC suma todas las alineaciones válidas

La secuencia de *keypoints* es mucho más larga que la de glosas y no está segmentada. **CTC** alinea ambas sumando todas las rutas válidas, sin anotar el instante exacto de cada signo.

DSTA: atención espacio-temporal desacoplada



Separar el modelado **espacial** (entre articulaciones) del **temporal** (a lo largo del tiempo) abarata el cómputo y respeta la estructura del esqueleto. Es el bloque base de **MSKA**.

Gracias por su tiempo